INFORME TÉCNICO

Detección, segmentación por fragmento y medición de fracturas pélvicas en CT con una red multitarea 2D propia

Gustavo Adolfo Chipantiza, Federico Gonzales Cárdenas, Juan Jacobo Delgado Melo y María de los Ángeles Valencia Hurtado

Analítica de Datos, Universidad Autónoma de Occidente, 2026-2. Profesor: Carlos Ferro

Proyecto integrador, corte 2 · octubre de 2026 · github.com/pengwin-analitica-2026/proyecto2-analitica-datos

Resumen. Presentamos un sistema que, en cada corte axial de una tomografía de pelvis, indica qué regiones óseas aparecen (sacro, coxal izquierdo y coxal derecho), las localiza con cajas, segmenta sus fragmentos y mide en milímetros cuánto se separó cada fragmento del fragmento principal de su hueso. Es una sola red 2D de 2.74 millones de parámetros, con backbone convolucional propio, atención CBAM y tres cabezas entrenadas desde cero, sin frameworks de detección ni de segmentación. Se entrenó y se evaluó con los 100 volúmenes públicos de PENGWIN, divididos por paciente en 70, 15 y 15. Al analizar los fallos encontramos que 34 de los 100 volúmenes están guardados girados 180° en el plano; enderezarlos a partir de la cabecera y entrenar con rotaciones de ±35° subió el Dice por fragmento en validación de 0.851 a 0.869. Siguiendo las correcciones del profesor, la orientación se calcula con productos punto y cruz sobre los metadatos, la rotación de entrenamiento se hace en milímetros y el modelo final (H7) no usa promedio exponencial de los pesos. En test, H7 cumple los nueve objetivos del curso, con un Dice por fragmento de 0.879. Es la tercera evaluación en test: la primera, con la configuración congelada antes de ver test, dio 0.845, y la segunda (H6), hecha después de analizar los fallos, 0.875. Un enderezado del giro del paciente recupera casi todo el rendimiento con pacientes girados 60° (de 0.636 a 0.855), y suavizar la imagen recupera el ruido leve. La distancia de separación tiene un error medio de 1.28 mm. La parte más débil son los fragmentos secundarios, con Dice de 0.750.

Palabras clave: fractura pélvica, tomografía computarizada, segmentación de instancias, aprendizaje multitarea, CBAM.

1. Introducción

Para planear la reducción quirúrgica de una fractura de pelvis hay que saber cuántos fragmentos hay, a qué hueso pertenece cada uno y cuánto se desplazó. Hacerlo a mano sobre una tomografía es lento. El reto PENGWIN 2024 [1] publicó tomografías con cada fragmento anotado y validado por expertos [2, 3]; el mejor método del reto alcanzó un IoU por fragmento de 0.930 en CT [1].

Este trabajo aborda el mismo problema con las restricciones del curso: arquitectura 2D corte a corte, backbone propio con CBAM [4] antes de bifurcar hacia las cabezas, tres cabezas entrenadas desde cero, detección con grid [5] y supresión de no máximos propios, y ningún framework de detección o segmentación de alto nivel. SAM [6] solo se usa como comparación. Nuestras cifras no son comparables con las del reto: usamos una partición propia de los 100 casos públicos y medimos corte a corte.

Los aportes son cuatro. Primero, una red ligera que resuelve clasificación, detección, segmentación por fragmento y medición en un solo paso. Segundo, el hallazgo de que un tercio del dataset está guardado en otra orientación, y la medida de cuánto afecta al modelo. Tercero, un protocolo de experimentos con el ruido medido entre semillas y con todas las consultas a test declaradas. Cuarto, la corrección de la orientación con los metadatos y una prueba de robustez a pacientes girados y a imágenes ruidosas.

2. Datos

Usamos los 100 volúmenes de CT con máscara de PENGWIN Task 1 [3], en formato .mha y con licencia CC BY 4.0. Cada vóxel de la máscara lleva el número de su fragmento: de 1 a 10 para el sacro, de 11 a 20 para el coxal izquierdo y de 21 a 30 para el coxal derecho. El primer número de cada región (1, 11 y 21) es el fragmento principal y los demás son fragmentos secundarios. Hay entre 3 y 9 fragmentos por caso (media 5.75). El

espaciado va de 0.66 a 1.22 mm en el plano y de 0.625 a 1.25 mm entre cortes. La partición es 70 / 15 / 15 por paciente, con semilla 42, y no se generaron etiquetas nuevas.

Cada corte se recorta a [−1024, 3000] HU, pasa por una ventana ósea (centro 400, ancho 1800) y una corrección gamma de 1.5, y se lleva a 384 × 384 píxeles.

Orientación. La cabecera de 34 de los 100 archivos indica que el volumen está guardado girado 180° en el plano axial (22 en entrenamiento, 10 en validación y 2 en test). En esos casos el sacro queda arriba y los coxales intercambian su lado en la imagen. El paso de orientación canónica lee la cabecera y endereza el volumen, igual en la imagen y en la máscara, en todos los conjuntos y sin usar las etiquetas. La orientación se obtiene con productos punto y cruz sobre la matriz de dirección de la cabecera, como en el método de Ferro Sánchez et al. [7]: el producto punto indica con qué eje del paciente coincide cada eje de la imagen, y el producto cruz de filas y columnas, hacia dónde van los cortes y si la imagen está en espejo.

3. Método

3.1 Arquitectura

Un backbone convolucional propio, con 32 canales base y un módulo CBAM en una etapa, alimenta tres cabezas en un solo paso hacia adelante (Figura 1). La cabeza de clasificación dice cuáles de las tres regiones aparecen en el corte. La de detección predice, en un grid de 24 × 24 celdas, la caja de la región cuyo centro cae en cada celda, y una supresión de no máximos propia deja una caja por región. La de segmentación tiene dos salidas: una semántica (fondo y las tres regiones) y una de instancia que, dentro de cada región, separa el fragmento principal de los secundarios. Los fragmentos secundarios individuales salen de las componentes conexas de esa salida, con un tamaño mínimo de 12 píxeles.

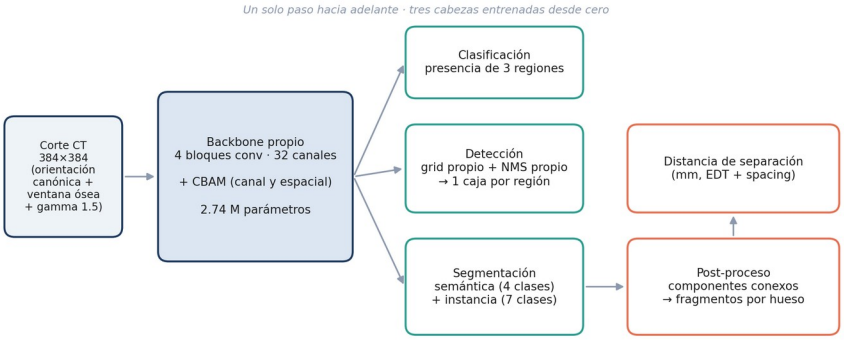


Figura 1. Arquitectura del modelo: un backbone compartido y tres cabezas entrenadas desde cero.

Para la cabeza de detección se consultó el principio del grid de YOLO [5]: cada celda predice la caja del objeto cuyo centro cae en ella. La cabeza, la asignación de celdas y la supresión de no máximos están escritas por el equipo, sin código ni pesos de YOLO, Detectron2 o Mask R-CNN. Cada decisión de diseño se tomó con una medida en validación (Tabla 1).

Tabla 1. Decisiones de arquitectura, su motivo y la evidencia en validación (Dice por fragmento salvo que se diga otra cosa).

Decisión	Motivo	Evidencia
32 canales base	El ancho del backbone era la limitación principal	Con 8, 16 y 32 canales: 0.829, 0.839 y 0.850. Con 48: 0.844
CBAM en una etapa, antes de las cabezas	Lo pide el curso; se probó en una y en tres etapas	mAP50 de 0.926 con una etapa, 0.907 con tres y 0.900 sin CBAM (40 épocas)
Instancia como principal o secundario por región	Lógica de dos etapas: primero la región y luego sus fragmentos. Es una tarea más acotada que predecir 31 identificadores	Con 31 identificadores: 0.787, y secundarios en 0.460. Con principal y secundario: 0.829 y 0.645
384 px por corte (el curso recomienda 224 a 256)	Hay fragmentos pequeños que a 256 px ocupan muy pocos píxeles	No se midió por separado en la serie final. Un lote de 16 con precisión mixta cabe en una GPU T4

Decisión	Motivo	Evidencia
Promedio exponencial de los pesos (EMA), solo hasta H6	Estabiliza el final del entrenamiento. Se retiró en H7 por pedido del profesor: puede hacer al modelo frágil con imágenes de mala calidad	Secundarios +0.016, +0.048 y +0.009 en tres semillas (D5). Sin EMA, H7 da 0.873 frente a 0.869 de H6
Sin preentrenamiento	El preentrenamiento del backbone no dio ganancia consistente	Sección 5.3

3.2 Pérdida y entrenamiento

La pérdida es una suma ponderada de los términos de las tres cabezas. Los pesos no se copiaron de otra implementación: cada uno responde a algo medido en los datos o en el entrenamiento (Tabla 2).

Tabla 2. Pesos de la pérdida y su justificación.

Término	Peso	Por qué
Detección	1	Peso de referencia
Clasificación	0.5	Es la tarea que converge primero: en la primera época el F1 ya es 0.907, cuando el mAP50 va en 0.287 y el Dice por fragmento en 0.529. Con más peso competiría con tareas que aún no aprenden
Semántica (entropía cruzada y Dice)	2 y 1	Es la primera de las dos etapas: un error de región arrastra a todos sus fragmentos
Instancia (entropía cruzada y Dice)	1 y 1	En la entropía cruzada los secundarios pesan el triple: son cerca de la mitad de los fragmentos y cerca de una décima parte del hueso. Con peso ×6 no superó el ruido (0.832 frente a 0.829) y con sobremuestreo ×3 empeoró (0.837 frente a 0.850)
Borde	1	Término auxiliar para el contorno de los fragmentos
Instancia y borde ×2, detección ×0.5	—	Alternativa probada: 0.855, dentro del ruido, y el mAP50 de la cabeza de grid baja de 0.868 a 0.827. Se dejan los pesos de arriba

El modelo se entrena desde cero con AdamW (tasa 2×10^{-3} con decaimiento coseno, lote de 16, precisión mixta), 60 épocas de 2 500 cortes. H6 usaba un promedio exponencial de los pesos (EMA, 0.999); el modelo final, H7, no lo usa. El aumento de datos combina espejo sagital con intercambio de las etiquetas de los coxales, cambios de intensidad y, en el modelo final, rotación de hasta ±35° (en milímetros en H7), escala, proporción y desplazamiento.

3.3 Volumen y distancia

Las predicciones de todos los cortes se apilan y un post-proceso 3D por región une cada fragmento a lo largo del volumen. La separación de un fragmento secundario es la distancia mínima borde a borde hasta el fragmento principal de su hueso, calculada con la transformada de distancia euclídea y el espaciado en milímetros de la cabecera. En inferencia se promedia la predicción del corte con la de su espejo (TTA).

4. Protocolo de evaluación

Todas las métricas se calculan sobre todos los cortes de cada volumen: 5 047 en validación y 4 664 en test. El Dice por fragmento compara cada fragmento real de un corte con el fragmento predicho que más se le superpone, y es la métrica más exigente de las nueve.

Cada experimento cambió una sola cosa. El ruido entre corridas se midió con tres semillas (±0.004 en el Dice por fragmento y ±0.012 en el de los secundarios), y un cambio solo se aceptó si mejoraba la validación por encima de ese ruido. Los modelos se eligieron únicamente con validación y con pruebas de estrés, que repiten la validación con los volúmenes girados.

Test se evaluó tres veces con modelos distintos. La primera, con el modelo D5 y la configuración congelada antes de ver test, es la cifra limpia. La segunda, con H6, se hizo después de estudiar por qué fallaban dos casos de test (012 y 039). H6 se eligió solo con validación y su configuración se fijó por escrito antes de evaluarlo, pero la decisión de investigar la orientación nació de mirar test, y por eso reportamos todas las cifras. La tercera, con H7, aplica las correcciones del profesor (sección 5.7) y también se eligió solo con validación. Contando dos variantes

que no se adoptaron (receta c2 y EMA con CASR), test se consultó cinco veces; todas están en la bitácora del repositorio.

5. Resultados

5.1 Métricas frente a los objetivos

El modelo final, H7, cumple los nueve objetivos en test (Tabla 3), igual que H6. La primera evaluación cumplía ocho: el Dice por fragmento quedaba en 0.845. Las tres semillas de H6 dan 0.875, 0.875 y 0.876; promediar los tres modelos da 0.879, pero triplica el costo y no se usa. La detección se reporta con la caja refinada con la máscara semántica; con H6, la cabeza de grid sola obtiene en test un IoU medio de 0.783, mAP50 de 0.912 y mAP50:95 de 0.556, que también cumplen. Los análisis de las secciones 5.4 a 6.2 se hicieron con H6, que comparte arquitectura con H7.

Tabla 3. Las nueve métricas del curso. Test: 15 casos; un modelo con TTA. Validación: H7.

Métrica	Objetivo	Test, 1.ª eval. (D5)	Test, 2.ª eval. (H6)	Test, 3.ª eval. (H7)	Validación (H7)
F1 de clasificación	0.85	0.984	0.990	0.989	0.992
AUC de clasificación	0.85	0.998	0.999	0.999	0.999
IoU medio de detección	0.65	0.898	0.943	0.940	0.948
mAP50 de detección	0.65	0.920	0.961	0.962	0.974
mAP50:95 de detección	0.40	0.853	0.902	0.899	0.903
Dice de segmentación semántica	0.85	0.949	0.971	0.971	0.971
IoU de segmentación semántica	0.70	0.904	0.943	0.944	0.944
Dice por fragmento	**0.85**	**0.845**	**0.875**	**0.879**	**0.873**
IoU por fragmento	0.70	0.781	0.816	0.819	0.812

La mejora no viene de un solo paciente: H6 sube en 13 de los 15 casos de test (Figura 2). Los dos que más cambian son los que motivaron el análisis, 012 (de 0.692 a 0.865) y 039 (de 0.710 a 0.784).

5.2 Qué aporta cada cambio

H6 añade dos cosas a D5: la orientación canónica y el aumento geométrico. Cada combinación se entrenó por separado (Tabla 4). Cada cambio aporta por su cuenta (+0.010 la orientación y +0.014 el aumento con ±12°) y juntos casi se suman (+0.023). La ganancia está en los fragmentos secundarios, que pasan de 0.703 a 0.764.

H5 y H6 empatan en la validación normal, dentro del ruido. Los separa la prueba de estrés (Figura 3): con la validación girada 30°, H6 conserva 0.854 y D5 cae a 0.559; con 60°, H6 baja a 0.734 y los demás quedan por debajo de 0.22. Elegimos H6 porque en el dataset hay pacientes girados dentro del escáner, como el caso 012. Esta prueba giraba la imagen en píxeles; la sección 5.7 la repite girando al paciente en milímetros.

Tabla 4. Componentes de H6. Dice por fragmento en validación, semilla 42; las dos últimas columnas repiten la validación con los volúmenes girados.

Modelo	Orientación canónica	Rotación al entrenar	Dice por fragmento	Dice secundarios	Secundarios sin pareja	Girada 30°	Girada 60°
D5	no	no	0.851	0.703	9.0 %	0.559	0.127
H1	no	±12°	0.864	0.743	7.5 %	0.771	0.212
H4	sí	no	0.861	0.742	8.8 %	—	—
H5	sí	±12°	0.873	0.769	6.2 %	0.807	0.218
H6	**sí**	**±35°**	**0.869**	**0.764**	**6.9 %**	**0.854**	**0.734**

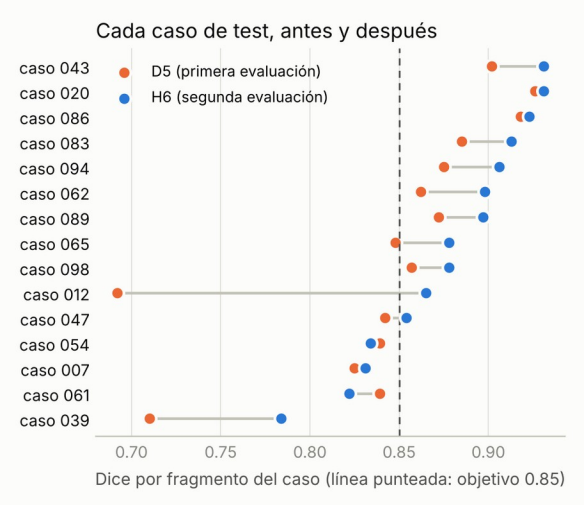


Figura 2. Dice por fragmento de cada caso de test en la primera evaluación (D5) y en la segunda (H6).

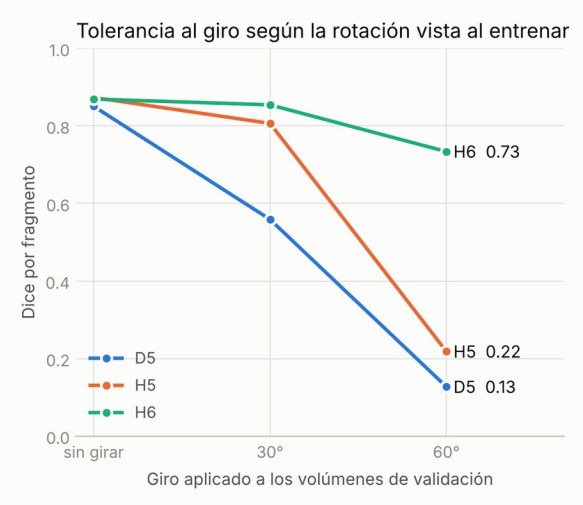


Figura 3. Dice por fragmento en validación según el giro aplicado a los volúmenes.

5.3 Estudio de ablación

Las ablaciones se midieron en validación sobre la receta de D5, que comparte arquitectura y pérdida con H6, cambiando una sola cosa (Tabla 5). CBAM mejora la clasificación y la detección y no cambia la segmentación. El backbone preentrenado en Intel Image Classification no da una ganancia consistente: los secundarios suben 0.011 con una semilla y bajan 0.008 con la otra, así que el modelo final no usa preentrenamiento.

Tabla 5. Ablaciones con y sin CBAM y con y sin transfer learning en el backbone (validación).

Ablación	Con	Sin
CBAM (semilla 42)	F1 0.988 · mAP50:95 0.883 · Dice por fragmento 0.851	F1 0.975 · mAP50:95 0.872 · Dice por fragmento 0.851
Transfer learning en el backbone (semillas 42 y 43)	Dice por fragmento 0.851 y 0.856 · secundarios 0.714 y 0.717	Dice por fragmento 0.851 y 0.855 · secundarios 0.703 y 0.724

5.4 Comparación con SAM

SAM ViT-B [6] se ejecutó en modo zero-shot sobre test, con la caja de nuestro detector como indicación, y se comparó con nuestra máscara semántica dentro de la misma caja (1 181 cortes, uno de cada tres; 3 002 pares corte-región). El modelo propio gana en las tres regiones y la mayor diferencia está en el sacro (Tabla 6). SAM, además, no separa ni clasifica fragmentos y no forma parte del sistema.

Tabla 6. SAM zero-shot frente al modelo propio en test.

Región	Dice SAM	Dice propio	IoU SAM	IoU propio
Sacro	0.792	0.884	0.690	0.820
Coxal izquierdo	0.915	0.947	0.859	0.905
Coxal derecho	0.930	0.957	0.879	0.921
Las tres regiones	**0.889**	**0.935**	**0.823**	**0.889**

5.5 Distancia de separación: predicción frente a ground truth

La distancia de cada fragmento secundario a su principal se calcula igual sobre la máscara predicha y sobre el ground truth del mismo caso, y se comparan (Tabla 7). En test hay 41 fragmentos secundarios y el modelo entrega distancia para 36. Con H6 el error medio es 1.28 mm y la correlación con la distancia real 0.82. Un solo fragmento del caso 007, que está a 9.4 mm y el modelo sitúa a 45.8 mm, concentra el 79 % del error; sin él la media es 0.28 mm. En validación solo 5 de los 41 secundarios están separados en el ground truth, así que esa columna es indicativa.

Tabla 7. Distancia predicha frente a la real y métricas de superficie por fragmento (41 secundarios en cada conjunto).

Medida	Validación, H6	Test, D5	Test, H6
Error medio de la distancia (mm)	0.185	2.956	1.277
Error del percentil 90 (mm)	0.000	3.453	0.556
Correlación con la distancia real	0.972	0.543	0.818
Secundarios con distancia predicha	38	36	36
Dice 3D, principal y secundarios	0.921 y 0.701	0.909 y 0.682	0.931 y 0.756
ASSD medio (mm)	4.08	3.02	2.06
HD95 medio (mm)	17.99	16.33	11.55

5.6 Latencia por imagen

La Tabla 8 da el tiempo de la red por corte de 384 × 384, con lote de 1. La configuración entregada es un modelo con TTA.

Tabla 8. Latencia por corte (mediana, en ms).

Configuración	GPU L4	CPU, 12 hilos	CPU portátil, 8 hilos
Un modelo	63.7	161.7	336.1
Un modelo con TTA (entregado)	71.6	249.6	695.5
Ensamble de tres semillas con TTA	87.4	518.0	—

5.7 Correcciones del profesor: orientación, EMA y robustez

Tras la entrega, el profesor pidió tres correcciones: normalizar las rotaciones con los metadatos usando productos punto y cruz [7], no usar el promedio exponencial de los pesos (EMA) y hacer el sistema robusto a imágenes de mala calidad. La orientación se calcula ahora con productos punto y cruz sobre la matriz de dirección de la cabecera (en los 100 casos coincide con la regla anterior). Se agregó además un enderezado opcional del giro del paciente en la camilla, que busca el ángulo de mayor simetría izquierda-derecha del hueso visto desde arriba y lo corrige en milímetros solo si es claro. El modelo final, H7, es la receta de H6 sin EMA y con la rotación de entrenamiento en milímetros: rotar en píxeles deforma la pelvis cuando los píxeles no son cuadrados, como en 10 de los 15 casos de validación. H7 cumple los nueve objetivos en validación y da 0.879 de Dice por fragmento en test (Tabla 3). La Tabla 9 compara H6 y H7 con pacientes girados en milímetros y con imágenes dañadas.

Tabla 9. H6 frente a H7 en validación, con pacientes girados (en milímetros) e imágenes dañadas. Dice por fragmento.

Prueba	H6 (EMA, giro en píxeles)	H7 (sin EMA, giro en mm)
Sin daño	0.869	0.873
Girado 60°	0.608	0.636
Girado 60° y enderezado	0.851	0.855
Desenfoque (σ = 1.5 px)	0.818	0.819
Ruido leve (σ = 10)	0.690	0.654
Ruido leve y suavizado (σ = 1)	—	0.851
Ruido fuerte (σ = 25)	0.135	0.228

El enderezado recupera casi todo el giro de 60° y casi no cuesta con pacientes derechos (0.872 frente a 0.873). El EMA no era la causa de la fragilidad: los dos modelos resisten el desenfoque y la baja resolución, y los dos caen con ruido. Suavizar la imagen antes del modelo recupera el ruido leve sin reentrenar, pero cuesta 0.014 en imágenes limpias, así que se aplica solo cuando la imagen viene ruidosa, con un aviso. Con H7, apagar CBAM al predecir baja el F1 de 0.992 a 0.444 y el mAP50 de 0.974 a 0.401: el modelo depende de CBAM sobre todo en clasificación y detección.

6. Análisis de error y limitaciones

6.1 Matriz de confusión de la clasificación

La cabeza de clasificación decide en cada corte si cada región está presente, así que hay una matriz de dos por dos por región (Tabla 10, sobre los 4 664 cortes de test). El error más frecuente es no detectar el sacro: pasa en 56 de los 2 294 cortes en que está.

Tabla 10. Matriz de confusión de la clasificación por región en test (H6, semilla 42).

Región	Presente y predicha	Ausente y predicha	Presente y no predicha	Ausente y no predicha	Precisión	Recall	F1
Sacro	2 238	37	56	2 333	0.984	0.976	0.980
Coxal izquierdo	3 372	11	12	1 269	0.997	0.996	0.997
Coxal derecho	3 316	28	4	1 316	0.992	0.999	0.995

A nivel de píxel (Tabla 11), casi todo el error de la máscara semántica es hueso que se predice como fondo, sobre todo en el sacro. La confusión entre coxal izquierdo y derecho, que con D5 llegaba al 13.7 % del hueso en el caso 012, queda por debajo del 0.1 %.

Tabla 11. Matriz de confusión de la segmentación semántica en test, en porcentaje de cada clase real (filas).

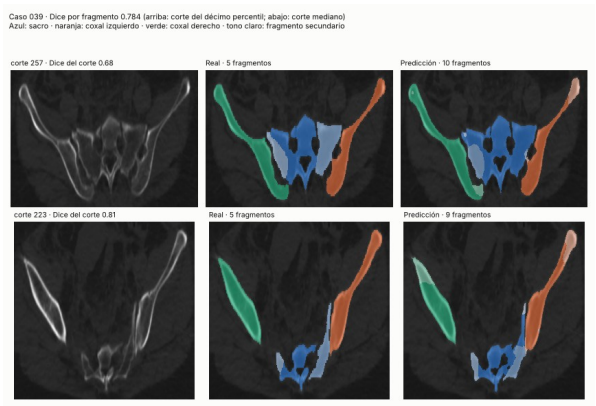
Real \ predicho	Fondo	Sacro	Coxal izquierdo	Coxal derecho
Fondo	99.93	0.02	0.02	0.02
Sacro	3.28	96.65	0.04	0.04
Coxal izquierdo	1.52	0.01	98.47	0.00
Coxal derecho	1.45	0.02	0.06	98.47

6.2 Los cinco peores casos

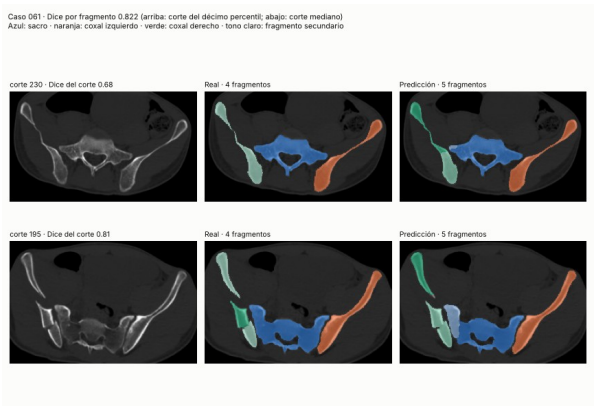
La Tabla 12 y la Figura 4 muestran los cinco casos de test con menor Dice por fragmento. En los cinco el fragmento principal se segmenta bien (entre 0.87 y 0.91) y el error está en los secundarios: lo que falta resolver ya no es a qué hueso pertenece cada píxel, sino dónde se parte el hueso en fragmentos.

Tabla 12. Los cinco peores casos de test con H6 y la causa más probable de cada uno.

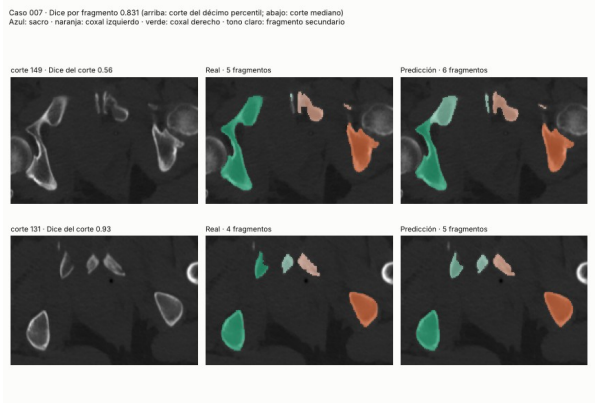
Caso	Dice	Principal	Secundarios	Sin pareja	Hipótesis
039	0.784	0.890	0.635	7.7 %	Es el volumen de menor resolución en el plano (154 × 322 px, 1.22 mm). Al llevarlo a 384 px el sacro sale dividido en más fragmentos de los reales
061	0.822	0.891	0.635	17.4 %	El coxal derecho tiene dos fragmentos grandes. El modelo ve un corte a la vez y en parte de los cortes intercambia cuál es el principal
007	0.831	0.913	0.545	24.5 %	Fragmentos secundarios pequeños en las ramas púbicas, y un coxal que el modelo parte donde el hueso se adelgaza. Uno de cada cuatro secundarios queda sin pareja
054	0.834	0.899	0.663	16.2 %	Fragmentos en contacto: el modelo predice fragmentos de más y confunde principal y secundario donde se tocan
047	0.854	0.870	0.753	17.1 %	Hueso fino y poco denso en los extremos del volumen (0.745 en los extremos y 0.888 en el centro). El 5.4 % del hueso se predice como fondo



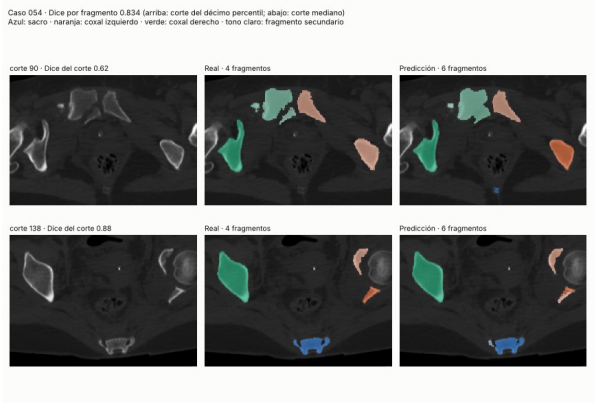
a) Caso 039



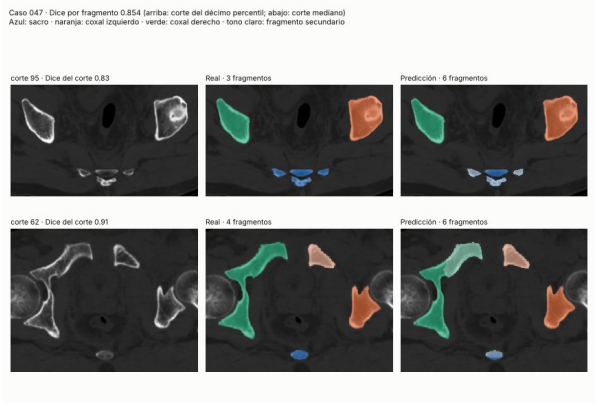
b) Caso 061



c) Caso 007



d) Caso 054



e) Caso 047

Figura 4. Galería de los cinco peores casos de test. En cada panel: imagen, fragmentos reales y fragmentos predichos, en el corte del décimo percentil (arriba) y en el corte mediano (abajo). Azul: sacro; naranja: coxal izquierdo; verde: coxal derecho; tono claro: fragmento secundario.

6.3 Limitaciones

- **Fragmentos secundarios.** Su Dice es 0.750 en test (H6) y el 7.8 % no tiene pareja en la predicción.
- **Fragmentos en contacto.** Cuando dos fragmentos se tocan, el modelo puede fusionarlos: el secundario se pierde y su distancia sale 0 mm o no existe.
- **Fragmentos de más.** El Dice por fragmento empareja cada fragmento real con uno predicho, pero no penaliza los fragmentos predichos que sobran.
- **Modelo 2D.** Procesa cada corte por separado; la coherencia entre cortes depende del post-proceso.
- **Orientación.** El modelo depende de la cabecera del archivo: la orientación se calcula con productos punto y cruz, pero un volumen oblicuo (inclinado respecto a los ejes) no se probó. El enderezado solo corrige el

giro en el plano axial, no el cabeceo ni la inclinación lateral, y falla con un campo de visión corto (caso 044).

- **Ruido.** Con ruido leve el Dice por fragmento baja de 0.873 a 0.654; el suavizado lo recupera (0.851), pero con ruido fuerte no llega al objetivo (0.658). La demo debe avisar cuando la imagen viene ruidosa.
- **Muestra.** Test tiene 15 pacientes de un solo dataset y se consultó cinco veces: las cifras de H6 y H7 no son estimaciones limpias. No se probó con otros centros ni escáneres.
- **Uso.** Es un trabajo académico. No es un dispositivo médico y no debe usarse para decisiones clínicas.

7. Conclusiones

Una red 2D propia de 2.74 millones de parámetros, sin frameworks de detección ni de segmentación, cumple en test los nueve objetivos del curso. La mejora que cerró la brecha no fue una red más grande: casi todas las variantes de arquitectura, pérdida y post-proceso que probamos quedaron dentro del ruido. Lo que funcionó fue revisar caso por caso por qué fallaba el modelo, encontrar que parte de los datos estaba en otra orientación y corregirlo con una regla fija. El trabajo pendiente está en los fragmentos secundarios en contacto, donde un modelo con contexto 3D debería ayudar. Las correcciones del profesor mantuvieron el rendimiento: H7, sin promedio exponencial de los pesos y con la orientación calculada con productos punto y cruz, da 0.879 en test, resiste pacientes girados gracias al enderezado y recupera el ruido leve con un suavizado previo.

Disponibilidad. El código, los pesos, los resultados de cada corrida y la bitácora de decisiones están en el repositorio. El dashboard con los tres visualizadores está publicado en Streamlit Community Cloud y la inferencia en vivo corre en una API en AWS Lambda. El uso de herramientas de IA durante el proyecto está documentado en IA_USAGE.md.

Referencias

[1] Y. Sang, Y. Liu, S. Yibulayimu et al., «Benchmark of Segmentation Techniques for Pelvic Fracture in CT and X-Ray: Summary of the PENGWIN 2024 Challenge», IEEE Transactions on Medical Imaging, vol. 45, n.º 5, pp. 2212-2228, 2026. doi:10.1109/TMI.2025.3650126.

[2] Y. Liu, S. Yibulayimu, G. Zhu et al., «Automatic pelvic fracture segmentation: a deep learning approach and benchmark dataset», Frontiers in Medicine, vol. 12, 1511487, 2025.

[3] Y. Sang, Y. Liu, S. Yibulayimu et al., «PENGWIN Task 1: Pelvic Fracture Segmentation on CT» (conjunto de datos, v1), Zenodo, 2024. doi:10.5281/zenodo.10927452. Licencia CC BY 4.0.

[4] S. Woo, J. Park, J.-Y. Lee e I. S. Kweon, «CBAM: Convolutional Block Attention Module», ECCV, 2018.

[5] J. Redmon, S. Divvala, R. Girshick y A. Farhadi, «You Only Look Once: Unified, Real-Time Object Detection», CVPR, 2016. Se consultó solo el principio del grid; la implementación es propia.

[6] A. Kirillov, E. Mintun, N. Ravi et al., «Segment Anything», ICCV, 2023.

[7] C. A. Ferro Sánchez, C. O. Díaz Laverde, S. E. Nope Rodríguez, G. A. Corrales Gallego, J. F. Aristizábal y O. I. Campo Salazar, «Methodology for the correction of a CBCT volume from the skull to the natural head position», MethodsX, vol. 13, 103073, 2024. doi:10.1016/j.mex.2024.103073.