Hoja de sustentación · Taller de Segmentación

Gustavo Chipantiza · Federico Gonzales · Juan Jacobo Delgado · María de los Ángeles Valencia — código del reto 2235112

> **La idea en una frase:** comparamos 4 programas que "pintan" dónde está un objeto en una foto, y luego unimos dos (YOLO y SAM) para que juntos lo hagan mejor que YOLO solo. Lo logramos: **0.9523 contra 0.9419**.

Qué decir (unos 8 minutos)

1. De qué trata (1 min)

"El taller trata de segmentación: decir, píxel por píxel, dónde está un objeto en una foto. Comparamos cuatro modelos y usamos dos colecciones de fotos: mascotas (Oxford Pets) y peatones (PennFudanPed)."

Mostrar: la tabla del mapa de la sesión al inicio del notebook.

2. Los cuatro modelos (2 min)

"**U-Net++** mira la foto completa y pinta cada píxel. **Mask R-CNN** primero encierra cada objeto en una caja y luego lo recorta dentro. **YOLO** hace lo mismo pero muy rápido. **SAM** recorta lo que tú le señales, pero no sabe qué es cada cosa: hay que decirle dónde mirar."

Mostrar: la figura de SAM con el punto en el ojo del gato (sección 4.4): su máscara más "segura" era solo el ojo.

3. Qué encontramos antes del reto (2 min)

"Sin entrenar nada, Mask R-CNN acertó 0.97 y YOLO 0.94 en las mascotas. YOLO no recorta mal: su promedio baja porque en 3 fotos no encontró a la mascota. Esa fue la pista para el reto."

"Además entrenamos Mask R-CNN con peatones (nota de 0.83) y vimos que YOLO es casi igual de bueno pero 6.7 veces más rápido. U-Net++ le ganó a U-Net por muy poco."

Mostrar: la gráfica de cajas (boxplot) de la sección 6.1, con los 3 puntos de YOLO en cero.

4. El reto (2 min)

"Hicimos un equipo: **YOLO busca** al perro o gato y le pasa una caja a **SAM, que lo recorta**. Si YOLO no encuentra ningún perro o gato, usamos un plan B de tres pasos: buscar con menos exigencia, aceptar cualquier animal, o usar el centro de la foto. Nunca usamos la respuesta correcta."

Mostrar: la salida de la evaluación (SUPERADO) y la figura de 4 filas: 2 fotos donde perdemos y 2 donde ganamos.

5. Lo más interesante (1 min)

"La ganancia no vino de que SAM recortara mejor. Vino del plan B: en 3 fotos YOLO sí vio al animal, pero creyó que era una **oveja** o un **oso**. A SAM no le importa el nombre, solo dónde está, y lo recortó casi perfecto. En las fotos normales SAM incluso empeoró un poco, sobre todo cuando el animal llenaba toda la foto."

Mostrar: la salida del diagnóstico (sheep, bear, bear) y la foto de la pomerania.

6. Cierre (30 s)

"Superamos a YOLO, pero el pipeline es 25 veces más lento. Lo mejor sería usar SAM solo cuando YOLO no encuentra nada. Gracias."

> **Si te bloqueas:** vuelve a la idea central. "YOLO encuentra, SAM recorta. Juntos ganaron porque SAM pudo recortar animales que YOLO vio pero nombró mal."

Los números que hay que saber

Qué	Número	Cómo decirlo
Nota de YOLO solo / nuestro equipo	**0.9419 / 0.9523**	"le ganamos por 0.0104"
Tiempo por foto: YOLO / equipo	**19 / 469 ms**	"unas 25 veces más lento"
De esos ms, cuánto es SAM "mirando" la foto	**393 ms (97 %)**	"casi todo el costo es el encoder de SAM"
Fotos donde ganamos / empatamos / perdimos	**46 / 3 / 51**	"perdemos en muchas, pero por muy poco"
Lo que aportó el plan B (3 fotos)	**+0.0298**	"más que toda la ganancia"
Lo que SAM quitó en las otras 97 fotos	**−0.0199**	"SAM no mejora lo que YOLO ya hacía bien"
Peor foto (perro de frente)	**0.99 → 0.30**	"la caja cubría toda la foto y SAM se confundió"
Mask R-CNN con peatones	**0.829**	"nota de detección de siluetas (mask AP)"

IoU (la "nota" de 0 a 1) = la parte donde la máscara y la respuesta correcta coinciden, dividida por toda el área que cubren entre las dos. 1 = perfecto, 0 = no se tocan.

Preguntas típicas y qué responder

¿Por qué ganaron si SAM empeoró casi todas las fotos?

Porque el plan B rescató 3 fotos que YOLO tenía en cero; esas subieron a 0.99 y compensaron de sobra lo que SAM bajó en las demás.

¿Por qué SAM falla cuando el animal llena la foto?

Porque la caja que le da YOLO es casi toda la foto, y así no le dice qué es animal y qué es fondo. Lo vimos también en la sección 4.4 con el gato blanco: SAM metió la manta.

¿Hicieron trampa?

No. Nunca usamos la respuesta correcta (el trimap) ni ajustamos números mirando las fotos una por una. Los umbrales y la caja central se fijaron antes.

¿Qué es la huella (SHA-256)?

Una "firma" de nuestras 100 máscaras. Si cambia un solo píxel, cambia la firma. Nos salió igual (97ef26c2…) cada vez que corrimos: el resultado se puede repetir.

¿Por qué SAM corre una sola vez por foto?

Porque "mirar" la foto (el encoder) cuesta 393 ms y "recortar" (el decoder) solo 14 ms. Si hay dos mascotas, se mira una vez y se recortan las dos juntas.

¿Qué es to_bgr?

YOLO espera los colores en otro orden (azul-verde-rojo). Si no se cambia, ve los colores al revés y detecta peor.

¿Cómo lo mejorarían?

Usar SAM solo cuando YOLO no encuentra perro o gato. Con nuestros datos daría una nota cercana a 0.972 y unos 33 ms por foto.

¿Diferencia entre IoU y Dice?

Las dos miden cuánto coinciden las máscaras. Dice siempre da un poco más alto: 2 × coincidencia ÷ (área A + área B).

¿Semántica vs instancias?

Semántica: "estos píxeles son perro". Instancias: "este es el perro 1 y este el perro 2".