PENGWIN · Correcciones del profesor: rotación, EMA e imágenes feas

Resumen completo de mediciones (H6 → H7)

No hay que entrenar ni ejecutar nada. Todo ya está corrido; los notebooks tienen sus salidas guardadas. Todo es en **validación (15 casos)**, salvo la sección 5 (test, una sola consulta con H7).

0. Qué hay en esta carpeta

Carpeta	Qué es
`RESUMEN_COMPLETO.pdf` / `.md`	Este documento
`notebooks/07_rotacion_H6_primera_prueba.ipynb`	**Primera prueba:** H6 (con EMA) con pacientes girados 30° y 60°, con y sin enderezado
`notebooks/09_H7_entrenamiento_validacion_test.ipynb`	**Entrenamiento de H7** (sin EMA) en Kaggle + validación H6 vs H7 + tercera evaluación en test
`notebooks/10_H7_ruido_y_CBAM.ipynb`	**Imágenes feas** (ruido, desenfoque, baja resolución) H6 vs H7 + **CBAM apagado** en H7
`modelos/`	`h7_..._noema_...pth` (modelo final) y `h6_..._ema_...pth` (anterior)
`resultados/`	Todos los JSON de métricas (validación, test, ruido, CBAM)
`figuras/`	Diagnóstico del giro del caso 044 y ejemplo de imágenes dañadas

En el notebook 09, la celda de validación que dice `^C` / `KeyError` se interrumpió a propósito (se reutilizó la validación de H6 del notebook 07); la que vale es **“nueva validacion”**. En el notebook 10 hay celdas repetidas: lo importante son **las dos últimas tablas**.

1. Qué pidió el profesor

1. Normalizar las rotaciones **con los metadatos**, usando **productos punto y cruz** (su artículo: Ferro Sánchez C. A. et al., “Methodology for the correction of a CBCT volume from the skull to the natural head position”, *MethodsX* 13:103073, 2024, doi:10.1016/j.mex.2024.103073).
2. **No usar EMA**: “con imágenes feas se puede destruir”.
3. Un **pipeline robusto** a imágenes feas, incluida la demo.

2. Los dos modelos

	H6 (antes)	H7 (final)
EMA	0.999	**0 (sin EMA)**
Giro de entrenamiento ±35°	en píxeles	**en milímetros** (`--aug-mm`)
Orientación	RAI (canónica)	RAI (canónica)
Resto	32 canales, CBAM 1, 60 épocas, lr 0.002, coseno, semilla 42	igual
Dónde se entrenó	—	Kaggle T4, 67 min, desde cero

Curva de H7 (Dice por fragmento en validación): época 20 → 0.827 · 30 → 0.816 · 40 → 0.863 · 50 → 0.872 · **60 → 0.875**.

3. Rotación

3.1 Paso 1 · Orientación con los metadatos (punto y cruz)

De la cabecera de cada CT se leen las direcciones de filas y columnas. **Producto punto:** con qué eje del paciente coincide cada eje de la imagen y si son perpendiculares. **Producto cruz** (filas × columnas): hacia dónde van los cortes y si la imagen está en espejo. Con eso todo queda en la misma orientación **RAI**; los 34 casos que venían en **LPI** se giran 180°. En los 100 casos coincide con lo que ya hacía `to_canonical`. (`src/normalizacion.py`)

3.2 Paso 2 · Giro del paciente en la camilla (enderezado)

El artículo endereza el cráneo (CBCT) a la posición natural de la cabeza; para pelvis usamos la **simetría izquierda-derecha del hueso** visto desde arriba. Solo corrige si el giro es claro (> 5° y mejora la simetría). Solo corrige el giro en el plano axial (no el cabeceo ni la inclinación lateral: limitación).

3.3 Lo que primero probé (y por qué se cambió)

- La prueba de estrés vieja `rot=X` giraba la imagen **en píxeles**. En **10 de los 15** casos de validación los píxeles no son cuadrados, así que eso **deformaba la pelvis** en vez de girarla.
- Señal del problema: en el caso **044** (píxeles 0.84 × 0.42 mm) el enderezado estimaba solo **+2.8°** para un giro de 30°. Ver `figuras/diag_044.png`.
- Corrección: nueva prueba `rotmm=X`, que gira X grados **en milímetros reales**, y el giro de entrenamiento en mm para H7.

Precisión del enderezado (sin modelo, ángulo estimado vs aplicado):

Giro aplicado	Error medio	Error máximo
30°	1.0° (0.3° sin el 044)	12° (044)
60°	2.8°	21° (044)

El 044 tiene solo ~16 cm de profundidad de campo: al girarlo, la pelvis se sale del recuadro. Ángulos estimados con `rotmm=60` (lo ideal ≈ 60° + el giro propio del paciente): mediana **58.3°**; todos entre 52° y 66°, salvo el 044 (39°). Con `rotmm=30`: mediana **31.0°**.

3.4 Primera prueba con modelo · H6 (notebook 07)

Prueba	F1	AUC	mAP50	IoU det.	Dice seg.	Dice fragmento
Sin giro	0.992	0.999	0.971	0.949	0.971	**0.869**
Girado 30°	0.990	0.999	0.943	0.927	0.961	0.853
Girado 30° + enderezado	0.992	0.999	0.971	0.945	0.959	0.854
Girado 60°	0.959	0.988	**0.311**	0.392	0.715	**0.608**
Girado 60° + enderezado	0.989	0.999	**0.963**	0.928	0.957	**0.851**

Lectura: con 60° el modelo se cae (mAP50 0.31); el enderezado lo recupera casi todo (0.96).

3.5 Ahora · H6 vs H7 (notebook 09)

Prueba	Modelo	F1	mAP50	IoU det.	Dice seg.	Dice fragmento
Sin giro	H6	0.992	0.971	0.949	0.971	0.869
	H7	0.992	0.974	0.948	0.971	**0.873**
Girado 60°	H6	0.959	0.311	0.392	0.715	0.608
	H7	0.951	0.347	0.426	0.725	**0.636**
Girado 60° + enderezado	H6	0.989	0.963	0.928	0.957	0.851
	H7	0.988	0.963	0.924	0.956	**0.855**

Lectura: en rotación, quitar el EMA no empeoró: H7 queda igual o un poco mejor que H6 en las tres pruebas.

4. H7 cumple las 9 métricas (validación)

Métrica	H7	Objetivo
F1 clasificación	0.992	0.85 ✔
AUC clasificación	0.999	0.85 ✔
IoU detección	0.948	0.65 ✔
mAP50	0.974	0.65 ✔
mAP50-95	0.903	0.40 ✔
Dice segmentación	0.971	0.85 ✔
IoU segmentación	0.944	0.70 ✔
Dice por fragmento	0.873	0.85 ✔
IoU por fragmento	0.812	0.70 ✔

5. Tercera evaluación oficial en test (H7)

	F1	AUC	mAP50	IoU det.	Dice seg.	Dice fragmento
H7 sin enderezar	0.989	0.999	0.962	0.940	0.971	**0.879**
H7 con enderezado	0.989	0.999	0.958	0.938	0.968	0.874

Evaluaciones oficiales (Dice por fragmento): 1.ª D5 **0.845** → 2.ª H6 **0.875** → 3.ª H7 **0.879**. Contando todas las consultas a test del proyecto (como el model card): c2 (0.848), EMA + CASR (0.847), D5 (0.845), H6 (0.875) y H7 (0.879) = **5 consultas**. En la de H7 se corrieron las dos variantes (sin y con enderezado) en la misma sesión; la principal es **sin enderezar**, que es la configuración validada (0.873 en validación). **¿El enderezado toca casos que no lo necesitan?** (revisado después, sin volver a evaluar test)

- En validación sin giro, con enderezado: Dice fragmento **0.872** vs 0.873 sin él. Solo corrigió 2 de 15 casos (014 +6°, 095 −6°): casi gratis.
- En test (leyendo la consulta ya hecha) corrigió 6 de 15: el **012 (+23°)**, el paciente girado conocido, y cinco con giros pequeños (5°–7°: 020, 054, 061, 062, 065). Esos giros pequeños explican la baja de 0.879 a 0.874.
- Mejora propuesta (sin usar test para decidir): subir el umbral de corrección de 5° a ~10°, para enderezar solo giros claros. Con ese umbral, en validación no cambia nada (los dos casos corregidos tenían 6°) y los giros de 30° y 60° se siguen corrigiendo. **Test no se vuelve a evaluar.**

6. Imágenes feas: H6 (EMA) vs H7 (sin EMA) · notebook 10

Ejemplo de cada daño: `figuras/imagenes_danadas_ejemplo.png`.

Daño	Modelo	F1	mAP50	Dice seg.	Dice fragmento
Sin daño	H6	0.992	0.971	0.971	0.869
	H7	0.992	0.974	0.971	**0.873**
Baja resolución (2.5)	H6	0.991	0.973	0.961	0.857
	H7	0.990	0.970	0.961	**0.861**
Borrosa (1.5)	H6	0.984	0.961	0.937	0.818
	H7	0.982	0.954	0.935	**0.819**
Ruido leve (10)	H6	0.881	0.690	0.889	**0.690**
	H7	0.879	0.730	0.825	0.654
Ruido fuerte (25)	H6	0.691	0.188	0.249	0.135
	H7	0.517	0.224	0.383	**0.228**

Lectura:

- Borrosa y baja resolución casi no afectan a ninguno de los dos.
- **El punto débil de los dos es el ruido**: con ruido leve pierden ~0.2 y con ruido fuerte se caen.
- **El EMA no era la causa; el ruido es el punto débil de ambos modelos.** Con ruido leve H6 aguanta algo mejor (0.690 vs 0.654); con ruido fuerte, H7 (0.228 vs 0.135).
- Como el desenfoque casi no daña, se probó **suavizar la imagen antes del modelo** (sección 6.1).

6.1 Suavizado antes del modelo (H7, sin reentrenar)

`suav=S`: filtro gaussiano de S píxeles aplicado **después** del ruido, sobre la imagen ya en 0–255 (como lo haría el pipeline de la demo).

Prueba	F1	mAP50	Dice seg.	Dice fragmento
Sin daño	0.992	0.974	0.971	**0.873**
Sin daño + suavizado 1	0.990	0.969	0.957	0.859
Ruido leve (10)	0.879	0.730	0.825	0.654
Ruido leve + suavizado 1	0.984	0.968	0.955	**0.851**
Ruido leve + suavizado 1.5	0.980	0.950	0.933	0.816
Ruido fuerte (25)	0.517	0.224	0.383	0.228
Ruido fuerte + suavizado 1	0.822	0.742	0.876	**0.658**

Lectura:

- **Con ruido leve, suavizar recupera casi todo**: 0.654 → 0.851 (mAP50 0.730 → 0.968), sin reentrenar.
- Con ruido fuerte recupera mucho (0.228 → 0.658) pero no llega al objetivo (0.85): ahí la demo debe **avisar** que el resultado no es confiable.
- En imágenes limpias el filtro **cuesta 0.014** (0.873 → 0.859): más que el umbral de 0.01, así que **no se aplica siempre**, solo cuando la imagen viene ruidosa.
- σ = 1 es mejor que 1.5.
- Regla para la demo: medir el ruido de la imagen → si es ruidosa, suavizar con σ = 1 y mostrar aviso de calidad; si es muy ruidosa, aviso de “resultado no confiable”. No hace falta un H8 con aumento de ruido para el ruido leve.

7. Aporte de CBAM en H7 (apagado al predecir) · notebook 10

Cabeza	Con CBAM	CBAM apagado	Caída
Clasificación (F1)	0.992	0.444	−0.55
Clasificación (AUC)	0.999	0.905	−0.10
Detección (mAP50)	0.974	0.401	−0.57
Detección (IoU)	0.948	0.281	−0.67
Segmentación (Dice)	0.971	0.678	−0.29
Fragmentos (Dice)	0.873	0.461	−0.41

Cuidado al presentarlo: esto mide cuánto **depende** H7 de CBAM, no cuánto **gana** por tenerlo. H7 se entrenó con CBAM; quitárselo de golpe lo descuadra, por eso caídas tan grandes. En la ablación anterior (semanas 9–10), entrenando un modelo **sin** CBAM, la diferencia fue pequeña: F1 0.988 vs 0.975 · mAP50:95 0.883 vs 0.872 · Dice fragmento 0.851 vs 0.851 (las mismas cifras del model card). Aparte, en la semana 10, al elegir dónde poner CBAM: un bloque mAP50 0.926, tres bloques 0.907, sin CBAM 0.900. Las cabezas que más dependen son **detección y clasificación**; la segmentación, menos. Para el aporte real en H7 habría que entrenar H7 sin CBAM (`--cbam none`, ~70 min en Kaggle).

8. Conclusiones

1. **Rotación con metadatos (punto y cruz):** hecho; todo queda en RAI.
2. **Paciente girado:** el enderezado recupera casi todo (60°: Dice fragmento 0.61 → 0.85; mAP50 0.31 → 0.96).
3. **Sin EMA:** H7 cumple las 9 métricas, iguala o mejora a H6 en rotación y queda cerca en ruido (H6 mejor con ruido leve, H7 con ruido fuerte). **H7 es el modelo final**, como pidió el profesor.
4. **Imágenes feas:** resiste desenfoque y baja resolución; **el ruido es el punto débil** (de ambos modelos), y **suavizar antes del modelo lo recupera** con ruido leve (0.654 → 0.851).

9. Lo que falta

- Demo: detector de ruido + suavizado σ = 1 solo si es ruidosa + aviso de calidad (umbral del detector por definir en validación).
- Subir el umbral del enderezado a ~10° (decidido en validación, sin nueva consulta a test).
- Model card: actualizar el conteo de consultas a test (ahora 5).
- Conectar el enderezado a la demo.
- Actualizar paper, model card y README con H7.
- (Opcional) Entrenar H7 sin CBAM para el aporte real.
- Limitaciones a declarar: solo se endereza el giro axial; el caso 044 (campo corto) se estima mal.

10. Cómo abrir el modelo (sin entrenar)

```
        import torch
        ck = torch.load("modelos/h7_auggeo_rot35_canon_aumm_noema_w32_e60_s42.pth", map_location="cpu", weights_only=False)
        print(ck["args"]["ema"], ck["args"]["canonical"], ck["args"]["aug_mm"], ck["args"]["base_channels"])   # 0.0 True True 32
```

Para evaluarlo: `python src/evaluate_volumes.py --checkpoint <pth> --cache-dir <caché> --split val --tta` (rama `feat/normalizacion-orientacion`).